

데이터 이해

컴퓨터와 데이터

인식

펴진 손가락수 /
접힌 손가락수



구별

가위 / 바위 / 보

컴퓨터로 처리

가위 / 바위 / 보

1 / 2 / 3

0 / 1 / 2

데이터 유형 1) 정형 데이터

이미 정해진 구조와 데이터 형식에 따라 저장된 데이터. 우리가 흔히 보는 표 형태로 구조화된 데이터

6개의 속성으로 구성
(각 속성별로 값의 범위나 유형이 규격화되어 있음)

속성 이름(헤더)	시:분	강수	기온	풍향	습도	해면 기압
행(레코드)	11:00	0	3.2	65.1	74	1029.5
	10:00	0	0.8	108.6	83	1029.9
	9:00	0	-0.8	65.1	92	1030.1
	8:00	0	-1.7	161.2	94	1029.9
	7:00	0	-1.7	96.4	94	1029.7
12개의 개별 데이터(샘플)	6:00	0	-1.7	0	94	1029.2
	5:00	0	-1.4	0	92	1029.2
	4:00	0	-0.7	119	90	1029.4
	3:00	0	-0.9	225.6	92	1029.9
	2:00	0	-0.9	331.7	91	1029.8
	1:00	0	-0.6	0	89	1029.8
	0:00	0	-0.1	189.7	87	1029.0
열(속성)	1열	2열	3열	4열	5열	6열

시간을 나타내는 값의 형태로 규격화되어 있음

장숫값의 형태로 규격화되어 있음

12시간 기상 관측 데이터 12시간 동안 변화된 여러 가지 기상 데이터를 표 형태로 구조화하고, 값의 범위나 유형을 규격화한 정형 데이터의 예이다.

반정형 데이터

정형 데이터처럼 표 형태로 구조화되어 있지는 않지만 내부에 구조 정보를 포함하고 있는 데이터. 주로 xml, JSON 등의 파일 형태로 표현됨.

정형 데이터의 분류

9개의 속성으로 구성

학번	이름	성별	키(cm)	발 크기(mm)	모델명	색상	사이즈	가격(원)
1101	강민지	여	155.2	211	N110	white	215	63,500
1102	김정현	남	172.9	263	AA11	black	265	49,900
1103	정지현	여	162.3	224	AA11	black	225	49,900
1104	이예슬	여	164.0	232	AA11	red	230	49,900
1105	박지용	남	178.5	270	N110	yellow	275	63,500
1106	최철민	남	181.9	282	RB00	red	280	35,000

이하 생략

'남' 또는 '여'의 2가지 범주를 나타내는 값들이 모여 있는 범주형 데이터

연속적인 값을 가진 연속형 데이터

값이 연결되어 있지 않고 끊어진 이산형 데이터




학생들의 신발 데이터

데이터의 분류



데이터 유형 2) 비정형 데이터

비구조적 데이터. 텍스트, 이미지, 오디오, 동영상 등 유용한 정보들이 데이터 내부에 숨겨져 있는 경우가 많음 .
특징 파악하거나 처리하기 어려운 편



▶ 한반도 위성 관측 영상

[출처] 기상청 날씨누리 사이트 <https://www.weather.go.kr/w/index.do>

데이터 유형 정리(종합)

정형 데이터 Structured

- 행과 열이 있는 표 형태로 정리된 데이터
- 예: 기상 관측 기록, 성적표, 센서 측정값
- 스프레드시트·데이터베이스에 저장, 통계 분석 용이

수치형 데이터 Numerical

- 연속형: 키(173.5cm), 기온(23.7°C) — 측정하는 값
- 이산형: 학생 수(28명), 방문 횟수 — 세는 값

비정형 데이터 Unstructured

- 정해진 구조가 없는 데이터 — 전체 데이터의 약 80%
- 예: 사진, 동영상, 뉴스 기사, 음성 녹음
- 딥러닝(CNN, 트랜스포머 등)으로 처리

범주형 데이터 Categorical

- 명목형: 혈액형(A/B/O/AB), 동아리명 — 순서 없음
- 순서형: 만족도(상/중/하), 학년 — 순서 있음


비정형 데이터를 정형화 한다면



그림 번호	편 손가락 수	엄지 위치	손바닥 방향	손목 위치	판정 결과
1	2	왼쪽	앞면	아래	가위
2	2	위	앞면	오른쪽	가위
3	0	왼쪽	앞면	아래	바위
4	0	위	앞면	오른쪽	바위
5	5	왼쪽	뒷면	아래	보
6	5	위	뒷면	오른쪽	보

▲ 이미지 데이터에서 속성을 찾은 예

비정형 데이터를 정형화 한다면(합성곱 신경망, CNN)



▲ 이미지 픽셀값을 속성값으로 사용한 예

비정형 데이터를 정형데이터로 변환해 보자



그림 번호	종류	색	모양			
1	사과	빨강	둥근 모양		겉	안 보임
2	딸기		뾰족한 모양			보임
3	귤	주황	둥근 모양		속	
4	바나나	초록	길쭉한 모양			
5						
6		노랑				
7				1		
8				3		
9				2		
10				1		
11				1		
12				1		

기계학습을 위한 데이터 선정 시 고려사항

문제 적합성

해결하고자 하는 문제와 관련 있는 데이터인지 확인한다.

수집 가능성

수집할 방법이 없거나 수집하기 어려운 데이터는 피하고, 수집할 수 있는 데이터를 선정한다.

정보 보호

선정하려는 데이터가 개인 정보를 포함하거나 저작권 침해의 문제가 없는지 살펴본다.

데이터의 품질

데이터의 정확성이나 데이터 제공자의 신뢰도가 떨어지는 데이터는 제외한다.

데이터 수집 비용

데이터를 수집하는 데 드는 비용을 고려하여 선정한다.

교과서 p.77

📍 데이터 선정 시 고려 사항

데이터를 수집하는 다양한 방법

